

City Pager / Lisbon Events Calendar

Pacote de replicacao - Pipeline & Inteligência

Terminus — Pipeline, Scrapers & Inteligência AI

Documento: 2 de 6 — Pipeline & Extração

Pacote: pipeline/ (Node + tsx, package.json próprio)

1. Objectivo do pipeline

Transformar posts Instagram de venues/promoters numa fila de eventos estruturados, com:

- artefatos AI auditáveis (cada tier gravado),
- auto-publish só com alta confiança,
- verificação online (Tier 5) sem editar automaticamente,
- revisão humana (Tier 6) para o resto,
- publish final para o CSV que a app consome.

Jobs longos: worker local (npm run worker), não Vercel.

2. Modos de execução

Modo | O que faz

profile-images | Fotos de perfil IG → bucket Supabase + Sheets primary_image_url

scrape | Posts IG → pipeline_posts (status=new)

extract | AI tiers em posts new + Tier 5 (salvo --skip-verify)

verify | Só Tier 5

full | scrape → extract (+ Tier 5). Não inclui profile-images

requeue | Reset posts → new

publish | Processed Events → Events Clean New (só linhas novas)

Flags úteis: --dry-run, --handle=a ou --handle=a,b,c, --limit=, --max-age-days=, --force-vision, --skip-verify, --from-apify-run=, --sheets-only (profile-images).

Admin /admin/scrapers enfileira em pipeline_runs; o worker faz claim e corre o mesmo CLI.

3. Scrapers (Apify)

Uso | Actor | ID default

Posts | apify/instagram-post-scraper | nH2AHrwxETRJoN5hX

Profiles | apify/instagram-profile-scraper | dSCLg0C3YEZ83HzYX

Watchlist SoT: catálogo Venues + Promoters (instagram_handle + is_active) via readPipelineWatchlist — Supabase após mig 025 + seed (CATALOG_SOURCE / WATCHLIST_SOURCE, default auto/catalog). Tabs Sheets Fontes IG só como fallback legado se o catálogo não tiver handles.

Fluxo scrape:

1. Ler handles activos do catálogo (ou Fontes se fallback).

2. Cutoff incremental (último scrape) ou --max-age-days.
 3. Correr Apify (batch ou per-account via PIPELINE_RUN_MODE).
 4. Transformar → EventsRawRow (scrapers/instagram-transform.ts).
 5. Arquivar imagens display via /api/admin/events/persist-image.
 6. Upsert pipeline_posts.
-

4. Orquestração por post (process-post.ts)

```
Tier 0 Pre-filter (descartar não-eventos)
Tier 1 Caption LLM (sempre, se keep)
    └ vision trigger? (faltam title / start / venue, ou --force-vision)
Tier 3 Carousel/image vision (+ OCR opcional)
    ou
Tier 4 Video frames + Whisper (flags)
Merge caption ↔ vision
Venue resolve + validate + fingerprint
→ pass → candidato Processed
→ review/fail → review queue
```

Nota: não existe módulo “Tier 2” separado; a numeração documentada salta 1→3/4. OCR e Whisper persistem como tiers ocr / video_transcript.

5. Inteligência por tier

Tier 0 — Pre-filter (intelligence/pre-filter.ts)

- Heurística: caption < 20 chars e não-carousel → discard.
- LLM (PIPELINE_TEXT_MODEL, default gpt-4o-mini): is_event_post, post_pattern, confidence.
- Patterns: single_event | multi_event | monthly_program | announcement | recap | not_event.
- Discard se is_event_post ou pattern recap/not_event.
- Parse failure → keep (evitar falsos discards).

Tier 1 — Caption (intelligence/broad-event-extraction.ts)

- Texto: caption + owner/location/posted_at/hashtags/links.
- Schema Zod: title, datetimes (Europe/Lisbon), venue, price, tags, confidence_score 0–1.
- Multi-event captions → vários eventos; extraction_source: 'caption'.

Trigger de vision (qualification/mandatory-fields.ts)

Vision só se: --force-vision, ou zero eventos caption, ou algum evento sem title, start_datetime válido, ou venue (pode usar location_name do IG).

Tier 3 — Vision carrossel (carousel-event-vision.ts)

- Até 10 slides; chunks de 2 imagens.
- Provider: NVIDIA NIM (nemotron-nano-12b-v2-vl) com fallback OpenAI gpt-4o.
- OCR Document AI opcional por slide → tier ocr.
- Campos: source_slide_indices, on_slide_text_evidence.

Tier 4 — Video (video-event-extraction.ts)

- Se media_type=video e PIPELINE_VIDEO_FRAMES / PIPELINE_VIDEO_WHISPER.
- ffmpeg ~4 frames; Whisper → video_transcript; vision multimodal.

Merge (merge-extractions.ts)

- Preferir vision para datetime se caption sem data ou confidence caption < PIPELINE_MERGE_CAPTION_DATETIME_THRESHOLD (0.8).
- Program split: se vision tem mais eventos e caption 1 → vision wins.
- Confidence final = min(caption, vision) – conflict penalties (nunca max). Conflitos de date/venue/price/is_free → tier_conflict na validação.
- Pós-merge: reconcile-post-events.ts colapsa lineup/slides do mesmo occurrence.

Validação (validate-event.ts) + auto-repair

Threshold publish: PIPELINE_PUBLISH_CONFIDENCE_THRESHOLD (default 0.7), mas o score é calculado (calculated-confidence.ts), não o self-report do modelo.

Auto-repair (antes da validação): overnight end rollover, 24:00→dia seguinte, limpar ticket URLs placeholder, limpar is_free+price conflict.

Código | Destino

missing_title, missing_or_invalid_start_datetime | fail
past_event, venue_unresolved, source_as_venue, end_before_start, bad_ticket_url, tier_conflict, implausible_duration, critical_field_inferred, low_confidence, program_undersplit, ... | review

Tier 5 — Verify online (event-verification.ts)

- Brave Search + LLM, ou OpenAI Responses + web_search_preview.
- Verdicts: verified | disputed | not_found | inconclusive.
- Nunca aplica correções automaticamente a Processed.
- Unclean / suggested_corrections → fila humana (online_verification_*).
- Publish só aceita clean verified (sem suggested_corrections) ou publish_auth=human_approved.

Tier 6 — Human review

- UI /admin/event-review sobre pipeline_review_queue (ordenado por start; Apply suggestions & approve).
- Approve → append Processed com publish_auth=human_approved; reject → fecha item.
- Feedback de qualidade → event_review_feedback (migration 018).
- Scripts: expire-review-queue, re-resolve-review-queue, unresolved-venues-report, quarantine-publish-unsafe.

6. Venue resolve & dedupe

Resolve (venue-resolve.ts): catálogo Venues (Supabase/Sheets) + aliases. Ordem: extracted name → location → owner só se source type=venue e não há venue extraído. Promoter/editorial nunca vira venue via owner fallback. venue_unresolved bloqueia auto-pass.

Candidates (pipeline_catalog_candidates): nomes de venue não resolvidos + @mentions desconhecidos → fila humana em /admin/catalog-candidates (aprovação escreve em venues/promoters). Separado da review de eventos.

Dedupe (dedupe.ts + app eventsLoader): fingerprint djb2 de source_post_id | YYYY-MM-DD | HH:mm(bucket 30min UTC) | title_norm | venueKey quando há source_event_id/source_url; senão legacy title|date|time|venue.
Batch: fica o de maior confidence; drop se já existe em Processed.

reconcile-post-events colapsa artist slides no mesmo venue+hora antes do fingerprint.

7. Modelos e env AI

Pass | Modelo / serviço

Texto (0, 1, parts of verify) | PIPELINE_TEXT_MODEL → gpt-4o-mini

Vision | Nemotron VL / gpt-4o

Whisper | whisper-1

Verify | PIPELINE_VERIFY_MODEL → gpt-4o + Brave opcional

OCR | Google Document AI

Credenciais mínimas: APIFY_API_TOKEN, OPENAI_API_KEY, SUPABASE_URL + service role, GOOGLE_SHEETS_ID + SA JSON. Vision NVIDIA: NVIDIA_NIM_API_KEY.

8. Worker

cli/worker.ts a cada ~10s:

1. Heartbeat em pipeline_config.worker_heartbeat_at.
 2. Claim oldest pipeline_runs com status=queued → running.
 3. Executar modo + params.
 4. success / error / aborted; log capped ~200k chars.
 5. Abort cooperativo entre posts se abort_requested.
-

9. Módulos-chave

Path | Papel

process-post.ts | Orquestração por post

cli/run.ts | Comandos CLI

cli/worker.ts | Fila

scrapers/* | Apify + transform

intelligence/* | Tiers AI

qualification/* | Mandatory fields, validate, venue, dedupe, auto-repair, publish-safe, reconcile, calculated confidence

sinks/supabase-store.ts | Persistência pipeline

sinks/sheets-writer.ts | Processed + Clean (+ profile image URLs no catálogo)

sinks/catalog-store.ts | Watchlist + venue/promoter catalog read

media/* | Archive imagens evento + profile pics

10. Como operar no dia-a-dia

```
cd pipeline && npm install
# configurar pipeline/.env
npm run worker      # terminal dedicado
npm run full -- --limit=10 --max-age-days=14
npm run publish
```

Ou via /admin/scrapers com worker online. Monitorizar heartbeat no hub /admin.

Runbook vivo no repo: docs/PIPELINE.md. Deep dive: 06-inteligencia-infraestrutura.md.